

# Лекция 7

Илья Yaroshevskiy

17 марта 2021 г.

## Содержание

<b>1 Критерии Сильвестра</b>	<b>1</b>
1.1 Достаточный условия	1
1.2 Необходимые условия	1
<b>2 Собственные значения</b>	<b>1</b>
<b>3 Общие принципы многомерной оптимизации</b>	<b>1</b>
3.1 Выпуклые квадратичные функции	1
3.2 Принципы многомерной оптимизации	2
3.2.1 Скорость сходимости(минимизирующих последовательностей)	3
3.2.2 Критерии окончания итерационного процесса	3

## 1 Критерии Сильвестра

### 1.1 Достаточный условия

1.  $H(x^*) > 0$  и  $x^*$  — локальный минимум  $\Leftrightarrow \Delta_1 > 0, \Delta_2 > 0, \dots, \Delta_n > 0$
2.  $H(x^*) < 0$  и  $x^*$  — локальный максимум  $\Leftrightarrow \Delta_1 < 0, \Delta_2 > 0, \dots, (-1)^n \Delta_n > 0$

, где  $\Delta_i$  — угловой минор

### 1.2 Необходимые условия

1.  $H(x^*) \geq 0$  и  $x^*$  — может быть локальный минимум  $\Leftrightarrow \Delta_1 \geq 0, \Delta_2 \geq 0, \dots, \Delta_n \geq 0$
2.  $H(x^*) \leq 0$  и  $x^*$  — может быть локальный максимум  $\Leftrightarrow \Delta_1 \leq 0, \Delta_2 \geq 0, \dots, (-1)^n \Delta_n \geq 0$

, где  $\Delta_i$  — главный минор

## 2 Собственные значения

**Определение.** Собственные значения  $\lambda_i$  ( $i = 1..n$ )  $H(x^*)_{n \times n}$  находятся как корни характеристического уравнения  $|H(x^*) - \lambda E| = 0$ . Если  $H(x)$  — вещественная, симметричная матрица, то  $\lambda_i$  — вещественные

## 3 Общие принципы многомерной оптимизации

### 3.1 Выпуклые квадратичные функции

$$f(x) = \frac{1}{2}ax^2 + bx + c$$

**Определение.** Функция вида

$$f(x) = \sum_{i=1}^n i = 1 \sum_{j=1}^n a_{ij}x_i x_j + \sum_{j=1}^n b_j x_j + c \quad (1)$$

Называется **квадратичной функцией  $n$  переменных**

Положим  $a_{ij} = a_{ij} + a_{ji} \Rightarrow$  симметрия. матрица  $A$

$$f(x) = \frac{1}{2}(Ax, x) + (b, x) + c$$

, где  $b = (b_1, \dots, b_n)^T \in E_n$  — вектор коэффициентов,  $x = (x_1, \dots, x_n)^T$ .  $x, y$  — скалярное произведение  
Свойства квадратичных функций:

1.  $\nabla f(x) = Ax + b$

$$\frac{\partial f}{\partial x_k} = \frac{\partial}{\partial x_k} \left( \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j + \sum_{j=1}^n b_j x_j + c \right) =$$

$$\frac{1}{2} \sum_{i=1}^n (a_{ik} + a_{ki}) x_i + b_k = \sum_{i=1}^n a_{ki} x_i + b_k$$

2.  $H(x) = A$ , где  $H(x)$  — Гессиан

$$\frac{\partial^2 f}{\partial x_i \partial x_k} = \frac{\partial}{\partial x_k} \left( \frac{\partial f}{\partial x_i} \right) = \frac{\partial}{\partial x_k} \left( \sum_{i=1}^n a_{ki} x_i + b_k \right)$$

3. Квадратичная функция  $f(x)$  с положительно определенной матрицей  $A$  сильно выпукла

$$A = \begin{vmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{vmatrix}$$

$$A - lE = \begin{vmatrix} \lambda_1 - l & 0 & \dots & 0 \\ 0 & \lambda_2 - l & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n - l \end{vmatrix}$$

В этом базисе все угловые миноры матрицы  $A$  и матрицы  $A - lE$  — положительны при достаточно малом  $l: 0 < l < \lambda_{\min} \Rightarrow f(x)$  — сильно выпукла

### 3.2 Принципы многомерной оптимизации

$$f(x) \rightarrow \min, x \in E_n$$

$$x^{k+1} = \Phi(x^k, x^{k+1}, \dots, x^0), x^0 \in E_n \quad (2)$$

— итерационная процедура(общего вида)

$\{x^k\}$ :

$$\lim_{k \rightarrow \infty} f(x^k) = f^* = \min_{E_n} f(x), \text{ если } U^* \neq \emptyset$$

$$\lim_{k \rightarrow \infty} f(x^k) = f^* = \inf_{E_n} f(x), \text{ если } U^* = \emptyset$$

, где  $U^*$  — множество точек глобального минимума функции  $f(x)$   
 $\{x^k\}$  + условие 2 = минимизирующая последовательность для  $f(x)$   
Если для  $U^* \neq \emptyset$  выполняется условие

$$\lim_{k \rightarrow \infty} \rho(x^k, U^*) = 0$$

, то  $x^k$  сходится к множеству  $U^*$ . Если  $U^*$  содержит единственную точку  $x^*$ , то для  $\{x^k\}$  сходящейся к  $U^*$  будет справедливо  $\lim_{k \rightarrow \infty} x^k = x^*$

**Определение.**  $\rho(x, U) = \inf_{y \in U} \rho(x, y)$  — расстояние от точки  $x$  до множества  $U$

*Примечание.* Минимизирующая последовательность  $\{x^k\}$  может и не сходиться к точке минимума

**Теорема 3.1** (Вейерштрасса). Если  $f(x)$  непрерывна в  $E_n$  и множество  $U^\alpha = \{x : f(x) \leq \alpha\}$  для некоторого  $\alpha$  непусто и ограничено, то  $f(x)$  достигает глобального минимума в  $E_n$

### 3.2.1 Скорость сходимости(минимизирующих последовательностей)

**Определение.**  $\{x^k\}$  сходится к точке  $x^*$  **линейно** (со скоростью геометрической последовательности), если  $\exists q \in (0, 1)$  :

$$\begin{aligned}\rho(x^k, x^*) &\leq q\rho(x^{k-1}, x^*) \\ \rho(x^k, x^*) &\leq q^k \rho(x^0, x^*)\end{aligned}\tag{3}$$

**Определение.** Сходимость называется **сверхлинейной** если

$$\rho(x^k, x^*) \leq q_k \rho(x^{k-1}, x^*)$$

, и  $q_k \xrightarrow[k \rightarrow \infty]{} +0$

**Определение.** Квадратичная сходимость:

$$\rho(x^k, x^*) \leq [c\rho(x^{k-1}, x^*)]^2, \quad c > 0$$

### 3.2.2 Критерии окончания итерационного процесса

$$\begin{aligned}\rho(x^{k+1}, x^*) &< \varepsilon_1 \\ |f(x^{k+1}) - f(x^k)| &< \varepsilon_2 \\ \|\nabla f(x^k)\| &< \varepsilon_3\end{aligned}\tag{4}$$

, где  $\varepsilon_i$  — заранее заданные точности

$$x^{k+1} = x^k + \alpha_k p^k, \quad k = 0, 1, \dots\tag{5}$$

, где  $p^k$  — направление поиска из  $x^k$  в  $x^{k+1}$ ,  $\alpha_k$  — величина шага

$$f(x^{k+1}) < f(x^k)$$

— условие выбора  $\alpha_k$

**Определение.** В итерационном процессе 5 производится **исчерпывающий спуск**, если величина шага  $\alpha_k$  находится из решения одномерной задачи минимизации:

$$\Phi_k(\alpha) \rightarrow \min_{\alpha}, \quad \Phi_k(\alpha) = f(x^k + \alpha p^k)\tag{6}$$

**Теорема 3.2.** Если функция  $f(x)$  дифференцируема в пространстве  $E_n$ , то в итерационном процессе 5 с выбором шага с ичерпывающим спуском для любого  $k \geq 1$ :

$$(\nabla f(x^{k+1}), p^k) = 0\tag{7}$$

— это значит что эти два вектора ортогональны

для  $\Phi_k(\alpha)$  необходимое условие минимума функции:

$$\frac{d\Phi_k(\alpha)}{d\alpha} = \sum_{j=1}^n \frac{\partial f(x^{k+1})}{\partial x_j} \cdot \frac{dx_j^{k+1}}{d\alpha} = 0$$

учитывая  $x_j^{k+1} = x_j^k + \alpha p_j^k \Rightarrow \frac{dx_j^k}{d\alpha} = p_j^k$

**Теорема 3.3.** Для квадратичной функции  $f(x) = \frac{1}{2}(Ax, x) + (b, x) + c$  величина  $\alpha_k$  исчерпывающего спуска в итерационном процессе

$$x^{k+1} = x^k + \alpha_k p^k, \quad \alpha_k = 0, 1, \dots$$

равна

$$\alpha_k = -\frac{(\nabla f(x^k), p^k)}{(Ap^k, p^k)} = -\frac{(Ax^k + b, p^k)}{(Ap^k, p^k)}\tag{8}$$